



FACULDADE DE TECNOLOGIA DO IPIRANGA
CURSO DE BIG DATA PARA NEGÓCIOS

Eduardo Jeremias Cardoso

Gabriely Silva dos Santos

Jennyfer Oliveira dos Santos

Murilo Jacyntho de Matos

Ricardo Bertolessi Souto Galdino

METODOLOGIAS DE PROJETOS DE BIG DATA
ANALYTICS

SÃO PAULO
2026

Etapas do CRISP-DM

1. Compreensão de Negócios

O e-commerce enfrenta dificuldades para prever a demanda, não apenas em períodos de pico, como Black Friday e Natal, mas também na operação do dia a dia. Sem previsões confiáveis, a empresa acaba tomando decisões desalinhadas: em alguns momentos há excesso de recursos, gerando custos desnecessários, e em outros falta capacidade, causando atrasos e perda de vendas.

Esses problemas afetam diretamente a experiência do cliente e indicadores importantes, como satisfação, retenção e eficiência operacional.

Diante disso, o objetivo do projeto é desenvolver um modelo que consiga prever a demanda com mais precisão, permitindo um melhor planejamento da operação.

As principais perguntas de negócio que orientam o projeto são:

- Qual será o volume esperado de pedidos em determinado período?
- Qual o nível ideal de alocação de recursos operacionais?
- Qual o impacto das campanhas de marketing sobre a demanda?
- A capacidade atual é suficiente para atender à demanda prevista?
- Qual o risco associado a atrasos ou ociosidade operacional?
- Como variáveis como tráfego e conversão influenciam o volume de vendas?

2. Compreensão dos dados

Para responder essas questões, são utilizados dados de diferentes áreas, como histórico de vendas, tráfego do site, campanhas de marketing, informações de estoque e calendário (feriados e datas especiais).

Essa etapa tem como foco entender os dados disponíveis, avaliar sua qualidade e identificar padrões iniciais, como períodos de maior venda e influência de promoções no comportamento dos clientes.

3. Preparação dos dados

Após o entendimento inicial, os dados passam por um processo de organização. Isso inclui limpeza de informações inconsistentes, tratamento de dados faltantes e padronização dos formatos.

Também são criadas novas variáveis que ajudam na análise, como indicadores de promoções ativas, volume recente de pedidos e proximidade de datas importantes. Por fim, os dados são organizados por período (como dia ou semana), preparando a base para a modelagem.

4. Modelagem

Para a previsão de demanda, foi escolhido o modelo Prophet, por sua capacidade de lidar bem com padrões ao longo do tempo, como sazonalidade e tendências, além de considerar eventos externos, como campanhas e datas comemorativas. Ele também é mais simples de interpretar e aplicar, o que facilita seu uso no contexto do negócio. O objetivo aqui é gerar previsões confiáveis sobre o volume de pedidos futuros.

5. Avaliação

O desempenho do modelo é avaliado comparando as previsões com os dados reais, utilizando métricas de erro. A avaliação é conduzida por meio de métricas como MAE e RMSE, além de validação prática baseada em simulações operacionais. O objetivo é verificar se o modelo contribui efetivamente para decisões mais assertivas de dimensionamento e planejamento.

6. Implementação

Na etapa final, o modelo é aplicado na prática por meio de dashboards, facilitando o acesso às previsões pelas áreas responsáveis. O modelo deve ser atualizado com frequência para acompanhar mudanças no comportamento da demanda. Com isso, a empresa consegue planejar melhor seus recursos, evitar atrasos, reduzir custos e melhorar a experiência do cliente.

ROTEIRO DE KDD

1. Seleção

Nesta etapa, os dados são filtrados e organizados para formar o conjunto de dados alvo ("Target Data"). São selecionadas as variáveis que têm potencial de impactar o volume de pedidos e o tempo de entrega, reunindo tanto informações de negócio quanto dados logísticos em uma base integrada.

Dados selecionados:

- Histórico de vendas e volume de pedidos por período
- Dados de tráfego do site e taxa de conversão
- Campanhas de marketing e datas promocionais
- Informações de estoque disponível
- Calendário de feriados e datas especiais
- Registros de geolocalização e prazos de entrega (foco inicial nas regiões Sul e Sudeste para estabelecer padrões de referência)
- Dados de desempenho logístico por região e canal de entrega

2. Pré-processamento /Limpeza

Fase de tratamento para garantir que a base de dados esteja livre de inconsistências e pronta para análise.

- **Limpeza:** Remoção de registros duplicados, inconsistentes ou fora do escopo temporal da análise
- **Tratamento de dados faltantes:** Aplicação de técnicas de imputação ou exclusão controlada de registros incompletos, garantindo que a base reflita a operação real
- **Eliminação de ruídos estatísticos:** Identificação e tratamento de outliers que possam distorcer os padrões de demanda, como registros de cancelamentos em massa, falhas sistêmicas de cadastro ou picos de vendas causados por eventos não recorrentes. O tratamento é feito de forma seletiva, outliers com explicação de negócio são mantidos como eventos especiais no modelo, enquanto os causados por erros de dados são removidos.
- **Padronização de formatos:** Ajuste de tipos de dados, unidades de medida e formatos de data para permitir a integração entre as diferentes fontes

3. Transformação

Processamento dos dados para formatos que facilitem a mineração e descoberta de conhecimento.

- **Organização Temporal:** Agrupamento dos dados por períodos específicos, como dia ou semana.
- **Engenharia de Atributos:** Criação de variáveis para identificar promoções, sazonalidade e proximidade de datas festivas.

- **Clusterização Regional:** Agregação de métricas de entrega para identificar a linearidade dos prazos por região.

4. Mineração de dados

Aplicação de algoritmos para extrair padrões e modelos preditivos a partir dos dados transformados.

- **Modelagem de Demanda:** Utilização do modelo Prophet para identificar tendências e prever o volume de pedidos futuros.
- **Análise Logística:** Aplicação de técnicas estatísticas para validar o padrão de tempo de entrega e a estabilidade da malha logística.
- **Foco:** Identificar a correlação entre a infraestrutura estabelecida e a constância das entregas no Brasil.

5. Interpretação

Transformação dos resultados técnicos em conhecimento estratégico para a empresa.

- **Validação Técnica:** Uso do Erro Médio Absoluto (MAE) e da Raiz do Erro Quadrático Médio (RMSE) para avaliar a precisão das previsões geradas pelo modelo.
- **Conclusão Analítica:** Identificou-se que os pedidos seguem um padrão de tempo de entrega linear, evidenciando uma logística bem estabelecida nacionalmente, com destaque para as regiões Sul e Sudeste.
- **Decisão Estratégica:** Mapeamento dos pontos-chave que geram essa eficiência para replicar o modelo nas demais regiões do Brasil, visando reduzir prazos e aumentar a satisfação do cliente.
- **Implementação:** Uso de dashboards para monitoramento contínuo e atualização do modelo conforme mudanças no comportamento de consumo.

SCRUM

1. Problema

Atualmente, a falta de previsões confiáveis faz com que a empresa tome decisões desalinhadas: em alguns momentos há excesso de recursos, gerando custos desnecessários, e em outros há falta de capacidade, causando atrasos e perda de vendas.

2. Objetivo do Projeto

Nosso projeto busca desenvolver um modelo capaz de prever a demanda com mais precisão, tanto em períodos de pico, como Black Friday e Natal, quanto no dia a dia, apoiando o planejamento e a tomada de decisão.

3. Definir os Papéis

Product Owner - Responsável por definir prioridades: Murilo Matos

Scrum Master - Organiza o processo e garantir que o time siga o planejamento: Eduardo Jeremias

Time (Execução):

Gabriely Santos - Cientista de dados

Jennyfer santos - Analista de dados

Ricardo Bertollessi - Desenvolvedor back-end

4. Backlog:

1. Épico: Fundação e Ingestão (Data Engineering)

- Mapeamento de Fontes de Dados: Identificar e catalogar as origens do histórico de vendas, tráfego, campanhas e estoques.
- Pipeline de Extração: Desenvolver scripts para extrair dados logísticos com foco inicial nas regiões Sul e Sudeste.
- Saneamento e Limpeza (Pre-processing): Implementar rotinas para remoção de inconsistências, tratamento de dados faltantes e eliminação de ruídos estatísticos.
- Padronização de Formatos: Ajustar os formatos das diferentes fontes para permitir a integração em uma base única ("Target Data").

2. Épico: Inteligência de Dados (Analytics & Feature Engineering)

- Análise Exploratória (EDA): Identificar padrões iniciais, como períodos de maior venda e a influência de promoções.
- Engenharia de Atributos Temporais: Criar variáveis que identifiquem a proximidade de datas festivas, feriados e o volume recente de pedidos.
- Clusterização Regional: Agregar métricas de entrega para validar a linearidade dos prazos por região.
- Cálculo de Indicadores de Marketing: Isolar variáveis que medem o impacto das campanhas sobre a demanda.

3. Épico: Ciência de Dados e Modelagem (Machine Learning)

- Desenvolvimento do Modelo Prophet: Configurar o algoritmo para lidar com sazonalidade, tendências e eventos externos.

- **Treinamento e Ajuste Fino:** Calibrar o modelo para gerar previsões confiáveis sobre o volume de pedidos futuros.
- **Validação Técnica (Métricas):** Avaliar a precisão do modelo utilizando as métricas MAE (*Mean Absolute Error*) e RMSE (*Root Mean Square Error*).
- **Simulações Operacionais:** Realizar testes práticos para verificar se as previsões suportam o dimensionamento correto de recursos.

4. Épico: Entrega e Operacionalização (Deployment)

- **Desenvolvimento de Dashboards:** Criar painéis visuais para facilitar o acesso às previsões pelas áreas de negócio.
- **Automação do Ciclo de Vida:** Implementar a atualização frequente do modelo para acompanhar mudanças no comportamento de consumo.
- **Mapeamento de Pontos-Chave:** Documentar a eficiência logística para replicar o modelo de sucesso do Sul/Sudeste em outras regiões do Brasil.
- **Monitoramento de KPI:** Estabelecer o acompanhamento de métricas de satisfação, retenção e redução de custos operacionais.

1ª Sprint

O objetivo do sprint é entregar a base de dados tratada ("Target Data") e a primeira análise exploratória.

- **Tarefa 1 — Desenvolvedor Back-end (Ricardo Bertolessi):**

Extração e padronização dos formatos de dados das diferentes fontes. Desenvolvimento dos pipelines de coleta automatizada a partir das origens mapeadas (histórico de vendas, tráfego, campanhas, estoques e dados logísticos).

- **Tarefa 2 — Desenvolvedor Back-end / Analista de Dados (Ricardo Bertolessi + Jennyfer Santos):**

Execução da limpeza e remoção de ruídos estatísticos. Tratamento de valores faltantes, correção de inconsistências e padronização dos registros para garantir uma base íntegra e confiável.

- **Tarefa 3 — Analista de Dados (Jennyfer Santos):**

Definição das variáveis-alvo que impactam o volume de pedidos e o tempo de entrega. Identificação de padrões iniciais e sazonalidades nos dados históricos por meio de análise exploratória (EDA), documentando os principais comportamentos observados.

- **Tarefa 4 — Analista de Dados (Jennyfer Santos):**

Identificação de padrões iniciais e sazonalidades nos dados históricos. Mapeamento de períodos de pico, tendências recorrentes e variações associadas a campanhas e datas especiais, gerando insumos para a etapa de modelagem.

- **Tarefa 5 — Cientista de Dados (Gabriely Santos):**

Avaliação da qualidade e da representatividade dos dados coletados para responder à pergunta central do projeto: os dados disponíveis são suficientes e adequados para treinar um modelo preditivo de demanda confiável?

Esta tarefa inclui análise de completude, consistência temporal e distribuição das variáveis, gerando um relatório de viabilidade que orienta as decisões de modelagem da próxima sprint.

Para guiar essa avaliação, o cientista de dados deve responder às seguintes perguntas:

- O que vai acontecer com a demanda?

Os dados históricos cobrem períodos suficientes para capturar sazonalidades recorrentes?

- Quando vai acontecer?

Existe consistência temporal nos registros sem lacunas, saltos ou períodos sem dados que comprometam a série histórica?

- Como podemos prever o volume de pedidos?

As variáveis disponíveis (tráfego, campanhas, estoque) têm correlação observável com o volume de vendas, indicando poder preditivo?

- O que podemos otimizar?

Com base nos dados, é possível identificar antecipadamente períodos de sobrecarga operacional ou ociosidade de recursos?

- Quais são os riscos do modelo?

Existem variáveis com muitos dados faltantes, distribuições muito assimétricas ou períodos atípicos que possam comprometer a confiabilidade das previsões?

KANBAN



DATAOPS

1. Coleta - De onde vêm os dados?

Os dados do projeto são extraídos de um banco de dados relacional que centraliza as principais fontes de informação do e-commerce: histórico de pedidos por período, volume de tráfego do site, registros de campanhas de marketing ativas e dados de estoque disponível. Esse banco é atualizado diariamente pelo sistema operacional da empresa, garantindo que o pipeline sempre trabalhe com os dados mais recentes do ciclo anterior.

2. Processamento - O que acontece com os dados?

Após a extração, os dados passam por três etapas sequenciais. Na limpeza, registros duplicados, inconsistentes ou fora do escopo temporal são removidos, e valores faltantes são tratados por imputação ou exclusão controlada. Na transformação, são criadas as variáveis necessárias para a modelagem, como agrupamento por dia e semana, indicadores de proximidade de datas festivas, flags de campanhas ativas e volume médio recente de pedidos. Na validação, verificações automáticas confirmam que os dados estão completos e dentro dos padrões esperados antes de seguirem para o armazenamento.

3. Armazenamento - Onde os dados ficam?

A base tratada é carregada em um Data Warehouse, estruturada em tabelas organizadas por período. Essa estrutura permite que tanto o modelo preditivo quanto os dashboards consultem os dados de forma eficiente, sem depender do banco operacional original, evitando impacto no sistema de produção da empresa.

4. Análise - O que é feito?

Com os dados disponíveis no Data Warehouse, o modelo Prophet é executado automaticamente, identificando tendências de longo prazo, sazonalidades semanais e anuais, e o impacto de eventos externos sobre o volume de pedidos. O resultado é um conjunto de previsões de demanda para os próximos dias e semanas, que alimenta tanto os relatórios de planejamento operacional quanto os alertas de capacidade para as áreas responsáveis.

5. Automação - Roda todo dia? Em tempo real?

O pipeline completo da coleta à geração das previsões é executado automaticamente uma vez ao dia, ao final do expediente, sem necessidade de intervenção manual. O intervalo diário é adequado ao ciclo de planejamento do projeto, pois as decisões operacionais são tomadas com base no fechamento do dia anterior. Não há processamento em tempo real, já que o volume e a natureza dos dados não exigem essa frequência.

6. Monitoramento - Como saber se deu erro?

O pipeline conta com dois mecanismos de controle. O primeiro monitora a chegada dos dados: se os arquivos ou registros esperados não estiverem disponíveis até o horário definido para execução, um alerta é disparado automaticamente para o time responsável, impedindo que o modelo rode com base incompleta. O segundo monitora a execução: logs registram o status de cada etapa do pipeline extração, limpeza, transformação, carga e modelagem. Se qualquer etapa falhar, o processo é interrompido imediatamente e o time é notificado com o detalhamento do erro, garantindo que dados incorretos ou desatualizados não cheguem ao dashboard nem influenciem decisões operacionais. execução: logs registram o status de cada etapa do pipeline extração, limpeza, transformação, carga e modelagem. Se qualquer etapa falhar, o processo é interrompido imediatamente e o time é notificado com o detalhamento do erro, garantindo que dados incorretos ou desatualizados não cheguem ao dashboard nem influenciem decisões operacionais.

Planejamento do Projeto de Big Data

Problema do Negócio	O e-commerce não consegue prever a demanda com precisão, resultando em excesso ou falta de recursos operacionais, causando atrasos nas entregas, perda de vendas e custos desnecessários em períodos de pico e no dia a dia
Fonte de Dados	Banco de dados relacional com histórico de pedidos, tráfego do site, campanhas de marketing, dados de estoque e calendário de feriados e datas especiais
Arquitetura	Extração do banco relacional - Processamento e limpeza (Python) - Armazenamento em Data Warehouse - Modelagem preditiva (Prophet) - Visualização em dashboard
Ferramentas	Python (processamento e modelagem), SQL (consulta ao Data Warehouse), Apache Airflow (orquestração do pipeline), Power BI / QuickSight (visualização)
Métrica de Sucesso	Redução do Erro Médio Absoluto (MAE) e da Raiz do Erro Quadrático Médio (RMSE) nas previsões de demanda, com melhora no dimensionamento operacional e redução de atrasos nas entregas

CANVAS

